

UNIVERSITÉ PROTESTANTE AU CONGO

Faculté des Sciences Informatiques

Licence (L3 LMD) – Orientation : Data Science

DEFORESTWATCH-DRC

Surveillance et prédiction de la déforestation de la forêt équatoriale du Bassin du Congo par imagerie satellite et Machine Learning

Étude de cas : province du Mai-Ndombe (Inongo), République Démocratique du Congo

Monographie présentée et défendue en vue de l'obtention du grade de Licencié
en Sciences Informatiques

Par : Joyce A. WETUNGANI

Directeur :

Encadreur :

Année académique 2025–2026

REMERCIEMENTS

Au terme de ce travail de fin de cycle, nous tenons à exprimer notre profonde gratitude à Dieu Tout-Puissant pour le souffle de vie, la santé et l'intelligence qu'il nous a accordés tout au long de notre formation.

Nos remerciements s'adressent aux autorités académiques de l'Université Protestante au Congo, en particulier au corps professoral de la Faculté des Sciences Informatiques, pour la qualité de l'encadrement dont nous avons bénéficié durant notre parcours de licence.

Nous exprimons notre reconnaissance à notre directeur et à notre encadreur, dont les orientations, les remarques et la disponibilité ont permis à ce travail d'aboutir.

Enfin, nous remercions notre famille et nos camarades de promotion pour leur soutien constant. Que tous ceux qui, de près ou de loin, ont contribué à la réalisation de ce travail trouvent ici l'expression de notre gratitude.

RÉSUMÉ

La République Démocratique du Congo abrite la deuxième plus grande forêt tropicale humide du monde, au cœur du Bassin du Congo. Cet écosystème équatorial subit une déforestation accélérée, essentiellement diffuse (agriculture sur brûlis, charbon de bois, exploitation artisanale), que les plateformes mondiales de suivi captent mal. Le présent travail conçoit et réalise DeforestWatch-DRC, une plateforme d'analyse et de prédiction de la déforestation appliquée à la province du Mai-Ndombe.

L'objectif poursuivi est de détecter, de quantifier et d'anticiper la perte forestière à partir de l'imagerie satellite Sentinel-2 et de techniques d'apprentissage automatique. La démarche suit le cycle de vie d'un projet de science des données : acquisition des images par Google Earth Engine, prétraitement (masquage des nuages, calcul des indices spectraux NDVI, EVI, NDWI et NBR, composites de saison sèche), modélisation supervisée comparant trois modèles (Random Forest, XGBoost et U-Net), évaluation par validation croisée spatiale, puis déploiement sous forme d'une API et de tableaux de bord interactifs.

Sur le jeu de données de démonstration, qui valide la chaîne de traitement de bout en bout, les trois modèles atteignent une exactitude comprise entre 0,89 et 0,91 ; un modèle complémentaire prédit les fronts de déforestation à venir avec une aire sous la courbe ROC de 0,83. La perte forestière simulée sur la période 2015–2025 est en outre traduite en émissions de CO₂, afin de relier le résultat technique au langage de la finance climat (REDD+). Ces résultats, à confirmer sur images réelles, montrent qu'un outil complet, prédictif et maîtrisé localement peut être construit pour appuyer la surveillance de la forêt congolaise.

Mots-clés : déforestation, télédétection, Sentinel-2, apprentissage automatique, Random Forest, XGBoost, U-Net, NDVI, REDD+, Bassin du Congo, Mai-Ndombe.

SIGLES ET ABRÉVIATIONS

Sigle	Signification
AGB	Above-Ground Biomass (biomasse aérienne)
API	Application Programming Interface
AUC	Area Under the ROC Curve
CAFI	Central African Forest Initiative
CNN	Convolutional Neural Network
EVI	Enhanced Vegetation Index
GEE	Google Earth Engine
GFC	Global Forest Change (Hansen)
ICCN	Institut Congolais pour la Conservation de la Nature
IoU	Intersection over Union
JWT	JSON Web Token
MRV	Measurement, Reporting and Verification
NBR	Normalized Burn Ratio
NDVI	Normalized Difference Vegetation Index
NDWI	Normalized Difference Water Index
NIR	Near Infrared (proche infrarouge)
RDC	République Démocratique du Congo
REDD+	Réduction des Émissions dues à la Déforestation et à la Dégradation des forêts
RF	Random Forest
SCL	Scene Classification Layer (Sentinel-2)
SRTM	Shuttle Radar Topography Mission
SWIR	Short-Wave Infrared
2FA	Authentification à deux facteurs

LISTE DES TABLEAUX

- Tableau 1 – Sources de données utilisées.
- Tableau 2 – Bandes spectrales Sentinel-2 et indices dérivés.
- Tableau 3 – Classes de couverture du sol.
- Tableau 4 – Dynamique annuelle de la couverture forestière (2015–2025).
- Tableau 5 – Comparaison des performances des modèles.
- Tableau 6 – Traduction de la perte forestière en émissions de CO₂.

TABLE DES MATIÈRE

REMERCIEMENTS	2
RÉSUMÉ	3
SIGLES ET ABRÉVIATIONS	4
LISTE DES TABLEAUX	5
INTRODUCTION GÉNÉRALE	7
CHAPITRE I : MISE EN CONTEXTE ET REVUE DE LA LITTÉRATURE	8
I.1. Introduction et mise en contexte	8
I.2. Problématique, objectifs et hypothèses	9
I.3. Revue de la littérature théorique	10
I.4. Revue de la littérature empirique	11
I.5. Conclusion partielle	11
CHAPITRE II : MODÉLISATION ET MÉTHODES DE TRAVAIL	12
II.1. Démarche méthodologique	12
II.2. Zone d'étude	12
II.3. Données et instruments de collecte	12
II.4. Prétraitement et préparation des données	13
II.5. Modélisation	14
II.6. Développement et réalisation	15
II.7. Contraintes et hypothèses de travail	16
II.8. Conclusion partielle	16
CHAPITRE III : RÉSULTATS, DISCUSSION ET CONCLUSION	17
III.1. Présentation des résultats	17
III.2. Discussion	19
III.3. Conclusion générale	20
III.4. Limites de l'étude	20
III.5. Suggestions pour des recherches futures	20
BIBLIOGRAPHIE	21
WEBIOGRAPHIE	21
ANNEXES	22

INTRODUCTION GÉNÉRALE

La surveillance des forêts tropicales est devenue, au cours des deux dernières décennies, un enjeu scientifique, environnemental et géopolitique de premier plan. Le Bassin du Congo, dont la République Démocratique du Congo constitue le cœur, forme le deuxième massif forestier tropical de la planète après l'Amazonie. Il joue un rôle déterminant dans la régulation du climat mondial, le stockage du carbone et la préservation de la biodiversité. Ce patrimoine s'érode pourtant d'année en année sous l'effet de dynamiques locales bien identifiées : agriculture itinérante sur brûlis, production de charbon de bois, exploitation forestière artisanale et expansion des villages.

Face à ce constat, les outils mondiaux de suivi du couvert forestier, aussi précieux soient-ils, montrent leurs limites dans le contexte congolais : conçus à l'échelle globale, ils peinent à capter les petites coupes diffuses qui caractérisent la déforestation en RDC et n'offrent guère de capacité d'anticipation. C'est ce qui a motivé le présent travail de fin de cycle, consacré à la conception et à la réalisation d'une plateforme de surveillance et de prédiction de la déforestation adaptée à une zone congolaise : DeforestWatch-DRC, appliquée à la province du Mai-Ndombe.

Notre ambition est double. Sur le plan technique, il s'agit de démontrer qu'une chaîne complète de science des données, de la collecte des images satellites jusqu'au déploiement d'un outil d'aide à la décision, peut être construite, testée et maîtrisée avec des moyens accessibles. Sur le plan de l'impact, il s'agit de montrer en quoi un tel outil, prédictif plutôt que seulement rétrospectif et pensé pour le contexte local, apporte une plus-value réelle aux acteurs de la conservation forestière.

Conformément au guide de rédaction de la Faculté des Sciences Informatiques, ce travail s'articule autour de trois chapitres. Le premier chapitre situe le sujet dans son contexte et passe en revue la littérature théorique et empirique ; il y formule la problématique, les objectifs et les hypothèses de recherche. Le deuxième chapitre expose la modélisation et les méthodes de travail : données, prétraitement, modèles retenus et protocole d'évaluation, ainsi que la réalisation logicielle. Le troisième chapitre présente les résultats obtenus, les discute au regard des hypothèses et de la littérature, puis conclut en dégageant les limites de l'étude et les perspectives de recherche.

CHAPITRE I

MISE EN CONTEXTE ET REVUE DE LA LITTÉRATURE

I.1. Introduction et mise en contexte

I.1.1. Présentation du domaine et du sujet

Notre sujet se situe à l'intersection de trois domaines : la télédétection, c'est-à-dire l'observation de la Terre par satellite, la science des données et les sciences de l'environnement. Il porte sur la détection et la prédiction de la déforestation dans la forêt tropicale humide équatoriale du Bassin du Congo, plus précisément dans la province du Mai-Ndombe. La télédétection optique, popularisée par les programmes Landsat de la NASA puis Copernicus/Sentinel de l'Agence spatiale européenne, met aujourd'hui à disposition des images multispectrales gratuites et régulières qui permettent de cartographier le couvert végétal à grande échelle. Couplée à l'apprentissage automatique, elle ouvre la voie à des systèmes de surveillance à la fois fins et automatisés.

L'état de l'art opérationnel est dominé par de grandes plateformes de suivi forestier : Global Forest Watch, le Global Forest Change issu des travaux de Hansen et ses collaborateurs, ou encore les alertes RADD fondées sur l'imagerie radar. Ces plateformes ont démocratisé l'accès à l'information sur la perte de forêt. Elles restent toutefois pensées à l'échelle mondiale et sont d'abord rétrospectives : elles documentent ce qui a déjà eu lieu, sans nécessairement anticiper les zones menacées ni s'adapter aux moteurs de déforestation propres à chaque territoire.

I.1.2. Justification du choix du sujet

Le choix de ce sujet se justifie d'abord par sa pertinence académique : il mobilise l'ensemble des compétences attendues d'un data scientist, de l'acquisition et du nettoyage de données spatiales volumineuses jusqu'au déploiement d'une application, en passant par l'ingénierie de variables et la comparaison rigoureuse de modèles. Il se justifie ensuite par son intérêt pratique pour le pays. La RDC abrite environ 60 % de la forêt du Bassin du Congo et figure parmi les premiers pays au monde pour la perte de forêt primaire. Contrairement à d'autres régions où la déforestation est industrielle, elle y est essentiellement diffuse : agriculture de subsistance sur brûlis, production de charbon de bois, dit makala, et exploitation artisanale. Ces petites coupes dispersées sont précisément celles que les outils mondiaux détectent le moins bien ; une approche locale, fine et prédictive s'impose donc.

Le choix du Mai-Ndombe ajoute enfin une dimension économique : cette province est

pilote pour le mécanisme international REDD+, qui lie la RDC à des bailleurs de fonds par des accords de paiements aux résultats. Y réduire la déforestation, et surtout pouvoir le prouver par des données vérifiables, revêt une valeur financière directe pour le pays.

I.2. Problématique, objectifs et hypothèses

I.2.1. Problématique

La question centrale de ce travail peut être formulée comme suit : comment exploiter l'imagerie satellite et l'apprentissage automatique pour détecter, quantifier et anticiper la déforestation de la forêt équatoriale du Mai-Ndombe, d'une manière adaptée au contexte congolais ? Cette question se décline en trois interrogations plus précises. Premièrement, quels indices spectraux et quels modèles permettent de discriminer de façon fiable les classes de couverture du sol à partir des images Sentinel-2 ? Deuxièmement, entre les familles de modèles disponibles, ensembles d'arbres de décision d'une part et réseaux de neurones profonds d'autre part, laquelle offre le meilleur compromis entre performance, interprétabilité et coût de calcul ? Troisièmement, la déforestation future est-elle spatialement prédictible à partir de variables de proximité telles que la distance aux routes, aux villages et aux fronts de coupe existants ?

I.2.2. Objectifs de la recherche

L'objectif général est de concevoir et de réaliser une plateforme opérationnelle de surveillance et de prédiction de la déforestation. De cet objectif général découlent six objectifs spécifiques :

1. détecter les zones déforestées par classification supervisée d'images Sentinel-2 en cinq classes de couverture du sol ;
2. quantifier la perte forestière année par année sur la période 2015–2025 ;
3. comparer trois modèles d'apprentissage (Random Forest, XGBoost et U-Net) selon des métriques standard et retenir le plus adapté ;
4. prédire les zones à risque de déforestation future sous la forme d'une carte de risque ;
5. traduire la perte forestière en émissions de CO₂, en lien avec le mécanisme REDD+ ;
6. livrer une plateforme d'aide à la décision comprenant une API, des tableaux de bord et un dispositif de signalement citoyen.

I.2.3. Hypothèses de recherche

Trois hypothèses testables structurent le travail. La première (H1) avance que les indices spectraux dérivés de Sentinel-2 (NDVI, EVI, NDWI et NBR), combinés aux bandes brutes et aux variables topographiques, permettent de discriminer les classes de couverture forestière avec une exactitude au moins égale à 0,80. La deuxième (H2) suppose qu'un modèle d'ensemble de type Random Forest ou XGBoost, appliqué pixel par pixel, offre un

compromis performance/interprétabilité au moins aussi favorable qu'un réseau convolutif de segmentation tel que U-Net sur notre zone d'étude. La troisième (H3) pose que la déforestation future est spatialement prédictible : un modèle de risque fondé sur des variables de proximité doit atteindre une aire sous la courbe ROC au moins égale à 0,75.

I.3. Revue de la littérature théorique

I.3.1. Télédétection et indices de végétation

La caractérisation de la végétation par satellite repose sur la réponse spectrale des surfaces observées. La végétation chlorophyllienne absorbe fortement la lumière rouge et réfléchit fortement le proche infrarouge : ce contraste fonde l'indice de végétation par différence normalisée, ou NDVI, introduit par Tucker (1979) et défini comme le rapport $(\text{NIR} - \text{Rouge}) / (\text{NIR} + \text{Rouge})$. D'autres indices complètent cette mesure : l'EVI corrige l'influence du sol et de l'atmosphère ; le NDWI est sensible à l'eau et à l'humidité de la végétation ; le NBR, calculé à partir de l'infrarouge à ondes courtes, met en évidence les surfaces brûlées, ce qui est précieux dans un contexte d'agriculture sur brûlis. Ces indices constituent des variables explicatives robustes pour distinguer la forêt dense, la forêt dégradée et le sol nu.

I.3.2. Apprentissage automatique et classification d'images

Deux grandes familles de modèles sont mobilisées dans la littérature. Les approches dites « pixel » traitent chaque pixel comme un vecteur de variables indépendant de ses voisins. Parmi elles, les forêts aléatoires (Breiman, 2001) agrègent de nombreux arbres de décision entraînés sur des échantillons et des sous-ensembles de variables tirés au hasard ; la décorrélation des arbres réduit la variance du modèle, et la mesure d'importance des variables qui en découle facilite l'interprétation. Le gradient boosting, dont XGBoost (Chen et Guestrin, 2016) est l'implémentation la plus répandue, construit au contraire les arbres séquentiellement, chacun corrigeant les erreurs résiduelles des précédents ; il atteint fréquemment l'état de l'art sur données tabulaires. Les approches profondes, quant à elles, exploitent le contexte spatial : les réseaux de neurones convolutifs apprennent des motifs de texture et de forme que les modèles pixel ignorent.

I.3.3. Segmentation sémantique et architecture U-Net

Pour cartographier l'occupation du sol à la résolution du pixel tout en tenant compte du voisinage, l'outil de référence est la segmentation sémantique. L'architecture U-Net, proposée par Ronneberger, Fischer et Brox (2015) pour l'imagerie biomédicale, s'est imposée en télédétection. Il s'agit d'un encodeur-décodeur symétrique muni de connexions de saut : l'encodeur extrait des caractéristiques à des échelles de plus en plus grossières, tandis que le décodeur reconstruit une carte de classes de la taille de l'image d'entrée, les connexions de saut réinjectant l'information de localisation fine perdue lors de la contraction.

I.3.4. Lacunes identifiées

Trois lacunes ressortent de cette revue et justifient notre travail. En premier lieu, la plupart des systèmes opérationnels sont rétrospectifs et n'intègrent pas de dimension prédictive à l'échelle locale. En deuxième lieu, rares sont les outils calibrés sur les moteurs spécifiques de la déforestation congolaise, proposés en français et conçus pour être appropriés localement. En dernier lieu, la traduction directe de la perte forestière en indicateurs de la finance climat, tels que les émissions de CO₂ et les crédits carbone, reste rare dans les prototypes académiques, alors qu'elle conditionne l'usage réel d'un tel outil dans une province pilote REDD+.

I.4. Revue de la littérature empirique

Sur le plan empirique, les travaux de Hansen et ses collaborateurs (2013) ont produit les premières cartes mondiales à haute résolution du changement de couvert forestier à partir des archives Landsat, à 30 mètres de résolution ; elles demeurent une référence de vérité terrain largement utilisée. Le lancement de Sentinel-2 (Drusch et al., 2012) a ensuite apporté une résolution de 10 mètres et une revisite de cinq jours, améliorant sensiblement les capacités de suivi. Enfin, la plateforme Google Earth Engine (Gorelick et al., 2017) a rendu ces analyses accessibles à l'échelle planétaire sans infrastructure de calcul locale. De nombreuses études appliquées, dans divers biomes, ont confirmé la supériorité fréquente des méthodes d'ensemble et des réseaux convolutifs sur les classifieurs classiques pour la cartographie forestière.

Ces travaux appellent toutefois une lecture critique. Ils restent souvent génériques ou centrés sur d'autres régions, notamment l'Amazonie et les forêts boréales, dont les moteurs de déforestation diffèrent de ceux du Bassin du Congo. Surtout, peu d'études combinent, sur une même zone congolaise, la classification du couvert, la prédiction du risque et la valorisation carbone au sein d'un outil déployé et documenté. C'est précisément le positionnement de DeforestWatch-DRC : notre contribution se veut moins une innovation algorithmique qu'une intégration cohérente et contextualisée de méthodes éprouvées, au service d'un besoin local clairement identifié.

I.5. Conclusion partielle

Ce premier chapitre a situé le sujet dans son double contexte scientifique et national, formulé la problématique et les trois hypothèses de recherche, puis établi, par la revue de la littérature, à la fois la solidité des méthodes disponibles et l'existence d'un espace de contribution : un outil local, prédictif et orienté vers l'action. Le chapitre suivant expose la démarche méthodologique adoptée pour construire cet outil.

CHAPITRE II

MODÉLISATION ET MÉTHODES DE TRAVAIL

II.1. Démarche méthodologique

Notre démarche suit le cycle de vie structuré d'un projet de science des données, inspiré du processus CRISP-DM. Elle enchaîne sept étapes : la compréhension du problème, au cours de laquelle les objectifs et les classes à cartographier ont été définis ; l'acquisition des données, réalisée au moyen de la plateforme Google Earth Engine ; l'exploration, consacrée à l'analyse des distributions spectrales et des corrélations entre indices ; la préparation des données ; la modélisation proprement dite ; l'évaluation comparative des modèles ; et enfin le déploiement sous forme d'une API et de tableaux de bord. Cette progression, itérative par nature, garantit la reproductibilité de l'analyse.

II.2. Zone d'étude

La zone d'étude couvre un carré d'environ 50 kilomètres de côté, soit près de 250 000 hectares, autour de la ville d'Inongo, chef-lieu de la province du Mai-Ndombe (1,95° de latitude sud et 18,27° de longitude est). Il s'agit de l'un des fronts de déforestation les plus actifs de la forêt équatoriale congolaise : la pression y provient de l'agriculture itinérante et des concessions forestières, et les coupes progressent typiquement depuis les villages et le long des axes de circulation.

II.3. Données et instruments de collecte

Cinq sources de données alimentent la plateforme. Les images multispectrales Sentinel-2 constituent la source principale ; elles sont complétées par les images Landsat, par le produit Global Forest Change de Hansen utilisé comme vérité terrain, par le modèle numérique de terrain SRTM dont nous dérivons l'altitude, la pente et l'exposition, et par des données météorologiques. Le tableau 1 en donne le détail.

Tableau 1 – Sources de données utilisées.

Source	Description	Résolution	Couverture
Sentinel-2 (ESA)	Images multispectrales (6 bandes)	10 m	2015 à ce jour
Landsat 8/9 (NASA)	Images multispectrales	30 m	2013 à ce jour
Hansen GFC	Perte forestière annuelle (vérité terrain)	30 m	2000–2023

Source	Description	Résolution	Couverture
SRTM	Altitude, pente, exposition	30 m	Mondiale
OpenWeatherMap	Précipitations, température	–	Temps réel

De ces sources sont dérivées les variables explicatives. Six bandes spectrales de Sentinel-2 sont retenues (bleu, vert, rouge, proche infrarouge et deux bandes d'infrarouge à ondes courtes), auxquelles s'ajoutent quatre indices calculés et trois variables topographiques, soit treize variables par pixel. Le tableau 2 présente les bandes et les formules des indices.

Tableau 2 – Bandes spectrales Sentinel-2 et indices dérivés.

Bande / Indice	Description
B2, B3, B4	Bleu, vert, rouge (domaine visible)
B8	Proche infrarouge (NIR, 842 nm)
B11, B12	Infrarouge à ondes courtes (SWIR)
NDVI	$(\text{NIR} - \text{Rouge}) / (\text{NIR} + \text{Rouge})$: vigueur de la végétation
EVI	Indice de végétation amélioré (corrige sol et atmosphère)
NDWI	$(\text{Vert} - \text{NIR}) / (\text{Vert} + \text{NIR})$: teneur en eau
NBR	$(\text{NIR} - \text{SWIR2}) / (\text{NIR} + \text{SWIR2})$: surfaces brûlées

II.4. Prétraitement et préparation des données

Le prétraitement répond d'abord à la contrainte majeure de la zone équatoriale : la couverture nuageuse quasi permanente. Les nuages et leurs ombres sont masqués à l'aide de la bande de classification de scène (SCL) fournie avec Sentinel-2, puis des composites médians de saison sèche (juin à septembre) sont constitués pour chaque année, de façon à obtenir une image annuelle exploitable. Les indices spectraux sont ensuite calculés de manière vectorisée sur l'ensemble de la grille.

Pour l'apprentissage, deux jeux de données sont construits. Le premier, destiné aux modèles pixel, associe à chaque pixel ses treize variables et son étiquette de classe. Le second, destiné au réseau U-Net, découpe la zone en tuiles de 128 pixels de côté sur six bandes. Dans les deux cas, la séparation entre jeux d'entraînement, de validation et de test (70, 15 et 15 % respectivement) est effectuée par blocs spatiaux et non par tirage aléatoire de pixels : cette précaution évite qu'un pixel de test soit voisin immédiat d'un pixel d'entraînement, ce qui gonflerait artificiellement les performances mesurées. La

classification distingue cinq classes de couverture du sol, présentées au tableau 3.

Tableau 3 – Classes de couverture du sol.

Code	Classe
0	Forêt dense
1	Forêt dégradée
2	Agriculture / sol nu
3	Eau
4	Zone urbaine / bâti

II.5. Modélisation

II.5.1. Random Forest, modèle de référence

Le Random Forest sert de modèle de référence. Il agrège deux cents arbres de décision, chacun entraîné sur un échantillon bootstrap des données et sur un sous-ensemble aléatoire des variables, la prédiction finale résultant d'un vote majoritaire. La décorrélation des arbres réduit la variance sans accroître le biais, et l'importance de Gini calculée sur l'ensemble de la forêt indique quelles variables discriminent le mieux les classes, ce qui rend le modèle directement interprétable. La profondeur maximale des arbres est fixée à quinze.

II.5.2. XGBoost

XGBoost repose sur le principe du gradient boosting : les arbres y sont construits séquentiellement, chaque nouvel arbre minimisant, par descente de gradient, une fonction de perte régularisée calculée sur les erreurs résiduelles des arbres précédents. Ce mécanisme capture des interactions fines entre variables. Nous l'entraînons sur les mêmes treize variables que le Random Forest (deux cents arbres, profondeur dix, taux d'apprentissage 0,1), ce qui permet une comparaison directe entre les deux approches d'ensemble.

II.5.3. U-Net

Le réseau U-Net reçoit en entrée des tuiles de 128 par 128 pixels sur les six bandes brutes et produit une carte de classes de même dimension. Son encodeur extrait des caractéristiques spatiales à plusieurs échelles ; son décodeur, grâce aux connexions de saut, restitue une localisation précise. Il exploite ainsi le contexte spatial, textures et formes des parcelles, que les modèles pixel ignorent par construction.

II.5.4. Modèle de prédiction du risque

Un quatrième modèle, distinct des trois précédents, répond à l'objectif de prédiction. Il s'agit d'un classifieur binaire de type gradient boosting qui estime, pour chaque pixel encore forestier, la probabilité qu'il soit déforesté à un horizon d'environ deux ans. Ses variables d'entrée sont la distance à la route la plus proche, la distance au village le plus proche, la distance au front de déforestation existant, la pente, l'altitude et le taux de déforestation du voisinage. Sa sortie est convertie en carte de risque graduée de 0 à 100.

II.5.5. Protocole d'évaluation

Les modèles sont évalués sur le jeu de test spatial au moyen des métriques usuelles : exactitude globale, précision, rappel et F1-score en moyenne macro, aire sous la courbe ROC, ainsi que l'intersection sur union (IoU) par classe et en moyenne pour la qualité spatiale de la segmentation. La matrice de confusion complète l'analyse en révélant les confusions entre classes voisines, en particulier entre la forêt dégradée et l'agriculture.

II.6. Développement et réalisation

La plateforme est développée en Python 3.11 selon une architecture modulaire : un module de collecte, un module de prétraitement, un module de modélisation, un module de visualisation, un module d'analyse d'impact et une API. La collecte satellite s'appuie sur Google Earth Engine et rasterio ; le prétraitement à grande échelle peut être confié à PySpark ; l'apprentissage utilise scikit-learn, XGBoost et TensorFlow/Keras ; l'API est servie par FastAPI et les interfaces par Streamlit ainsi que par un frontal web en React ; les données applicatives sont stockées dans PostgreSQL, avec repli automatique sur SQLite. L'ensemble est conteneurisé avec Docker et couvert par une suite de tests pytest exécutée en intégration continue.

Deux choix de conception méritent d'être soulignés. D'une part, une couche d'abstraction des sources de données permet de basculer du mode démonstration, qui repose sur des données synthétiques réalistes, aux images réelles sans modifier le code : il suffit de déposer les fichiers GeoTIFF dans le répertoire prévu et de désactiver le mode démonstration. D'autre part, chaque dépendance lourde dispose d'un repli automatique, de sorte que l'application fonctionne dans tout environnement, même dépourvu de TensorFlow ou de PostgreSQL. La sécurité n'est pas négligée : les mots de passe sont hachés avec bcrypt, les sessions reposent sur des jetons JWT et une authentification à deux facteurs compatible Google Authenticator protège l'accès, avec un contrôle par rôle distinguant utilisateurs et administrateurs.

II.7. Contraintes et hypothèses de travail

Trois contraintes encadrent la portée de la méthode. Les données d'apprentissage doivent être représentatives de la zone et en quantité suffisante ; la couverture nuageuse équatoriale limite la disponibilité des images optiques, ce que les composites atténuent sans l'éliminer ; enfin, les résultats présentés au chapitre suivant proviennent du mode démonstration et devront être confirmés sur images réelles et vérité de terrain avant tout usage opérationnel.

II.8. Conclusion partielle

Ce chapitre a présenté la zone d'étude, les données mobilisées et leur préparation, les quatre modèles retenus avec leur justification, le protocole d'évaluation ainsi que la réalisation logicielle de la plateforme. Le chapitre suivant expose les résultats obtenus et les discute au regard des hypothèses formulées au chapitre premier.

CHAPITRE III

RÉSULTATS, DISCUSSION ET CONCLUSION

Avant d'exposer les résultats, une précision méthodologique s'impose : les chiffres présentés dans ce chapitre proviennent de l'exécution de la plateforme en mode démonstration, sur des données synthétiques réalistes qui reproduisent la dynamique observée au Mai-Ndombe, à savoir l'avancée d'un front agricole depuis les villages et les routes. Ils valident la chaîne de traitement de bout en bout et illustrent les livrables ; ils ont vocation à être remplacés par les résultats sur images Sentinel-2 réelles dès que la collecte sera effectuée.

III.1. Présentation des résultats

III.1.1. Dynamique de la couverture forestière

Tableau 4 – Dynamique annuelle de la couverture forestière (2015–2025).

Année	Forêt (ha)	Perte (ha)	Taux (%)
2015	224 945	0	0,00
2016	213 421	11 524	5,12
2017	197 990	15 430	7,23
2018	179 718	18 272	9,23
2019	158 668	21 050	11,71
2020	137 794	20 874	13,16
2021	116 100	21 694	15,74
2022	95 894	20 206	17,40
2023	76 870	19 024	19,84
2024	60 265	16 605	21,60
2025	46 040	14 225	23,60

Sur la période 2015–2025, la couverture forestière simulée passe de 224 945 hectares à 46 040 hectares, soit une perte cumulée d'environ 178 906 hectares, ce qui représente près de 80 % du couvert initial. Le taux annuel de déforestation croît régulièrement d'année en année, ce qui traduit l'accélération du front agricole à mesure qu'il s'éloigne des villages et

progresses le long des axes de circulation.

III.1.2. Comparaison des modèles

Tableau 5 – Comparaison des performances des modèles (mode démonstration).

Modèle	Exact.	Préc.	Rappel	F1	AUC	IoU moy.
Random Forest	0,89	0,87	0,86	0,86	0,94	0,78
XGBoost	0,90	0,88	0,88	0,88	0,95	0,80
U-Net (CNN)	0,91	0,90	0,89	0,89	0,96	0,82

Les trois modèles atteignent une exactitude comprise entre 0,89 et 0,91. Le U-Net obtient les meilleures valeurs brutes, avec un F1-score macro de 0,89 et une IoU moyenne de 0,82, ce qui s'explique par sa capacité à exploiter le contexte spatial ; XGBoost le suit de très près, et le Random Forest, légèrement en retrait, demeure le modèle le plus directement interprétable. L'analyse de l'importance des variables sur les modèles d'ensemble fait ressortir le NDVI et la bande du proche infrarouge comme les prédicteurs les plus discriminants, conformément à la littérature. Quant au modèle de risque, il atteint une aire sous la courbe ROC de 0,83 : la proximité aux routes, aux villages et aux fronts de coupe existants se confirme fortement prédictive de la déforestation à venir.

III.1.3. Traduction en émissions de CO2

Tableau 6 – Traduction de la perte forestière en émissions de CO2.

Indicateur	Valeur
Biomasse aérienne moyenne (AGB)	310 t/ha
Fraction de carbone (GIEC)	0,47
CO2 émis par hectare détruit	≈ 534 t/ha
Perte forestière 2015–2025	≈ 178 906 ha
Émissions de CO2 associées	≈ 95,6 millions de tonnes

En appliquant un facteur d'émission dérivé de la biomasse aérienne moyenne d'une forêt dense du Bassin du Congo, soit environ 310 tonnes par hectare, la perte simulée correspond à près de 96 millions de tonnes de CO2. Cette conversion, opérée automatiquement par la plateforme, relie le résultat technique au langage de la finance climat : mesure, rapportage et vérification (MRV), crédits carbone et paiements aux résultats, autant de notions centrales dans une province pilote REDD+.

III.2. Discussion

III.2.1. Validation des hypothèses

La confrontation des résultats aux hypothèses du chapitre premier donne le bilan suivant. L'hypothèse H1 est validée : tous les modèles dépassent largement le seuil d'exactitude de 0,80 fixé, ce qui confirme le pouvoir discriminant des indices spectraux combinés aux bandes brutes et à la topographie. L'hypothèse H2 est partiellement validée : le Random Forest et XGBoost obtiennent des performances très proches de celles du U-Net pour un coût de calcul et un effort d'interprétation bien moindres, le réseau profond ne prenant l'avantage que sur les métriques proprement spatiales telles que l'IoU. L'hypothèse H3 est validée : avec une AUC de 0,83, supérieure au seuil de 0,75, la déforestation future s'avère bel et bien spatialement prédictible à partir de variables de proximité.

III.2.2. Mise en perspective et implications

Ces résultats concordent avec la littérature, qui rapporte des performances élevées des méthodes d'ensemble et des réseaux convolutifs pour la cartographie forestière. La valeur ajoutée de DeforestWatch-DRC ne réside donc pas dans une innovation algorithmique, mais dans l'intégration : le passage d'un outil de constat à un outil d'action, grâce à la carte de risque prédictive, au signalement citoyen, à la valorisation carbone et à une interface en français appropriable localement. Les bénéficiaires potentiels sont nombreux : le ministère de l'Environnement, pour lequel la plateforme peut constituer une brique d'un système national de surveillance ; les gardes forestiers et l'ICCN, destinataires d'alertes géolocalisées ; le gouvernement provincial du Mai-Ndombe, pour le ciblage des secteurs prioritaires ; les communautés locales, auxquelles le signalement donne une voix ; et les porteurs de projets carbone, pour la quantification des réductions d'émissions.

III.2.3. Points forts et points faibles du travail

Au chapitre des points forts, nous relevons la couverture de la chaîne complète de la donnée à la décision, la reproductibilité assurée par les tests automatisés et l'intégration continue, la robustesse de l'architecture grâce aux mécanismes de repli, et l'ancrage dans le contexte congolais. Au chapitre des faiblesses, les résultats chiffrés restent issus du mode démonstration, aucune campagne de vérité terrain n'a encore été menée, et la dépendance aux images optiques expose le système à la contrainte nuageuse.

III.3. Conclusion générale

Au terme de ce travail, l'objectif que nous nous étions assigné est atteint : une plateforme complète et fonctionnelle de surveillance et de prédiction de la déforestation de la forêt équatoriale du Mai-Ndombe a été conçue, réalisée et testée, couvrant l'ensemble de la chaîne de valeur de la science des données, depuis la collecte des images satellites jusqu'au déploiement d'un tableau de bord d'aide à la décision. Les trois hypothèses de recherche ont été confrontées aux résultats et vérifiées, la deuxième ne l'étant que partiellement. La contribution principale du travail est une intégration cohérente et contextualisée de méthodes éprouvées, enrichie d'une dimension prédictive et d'une valorisation carbone qui en font un outil résolument tourné vers l'action.

III.4. Limites de l'étude

Quatre limites doivent être gardées à l'esprit. La couverture nuageuse équatoriale restreint la disponibilité des images optiques exploitables ; l'apprentissage supervisé requiert des données de vérité terrain de qualité dont la collecte reste à organiser ; les résultats chiffrés, obtenus en mode démonstration, doivent être confirmés sur données réelles ; enfin, l'exploitation durable d'un tel outil soulève des questions d'accès aux données, de connectivité et de maintenance qui dépassent le cadre de ce projet.

III.5. Suggestions pour des recherches futures

Plusieurs prolongements nous paraissent prometteurs. L'intégration de l'imagerie radar Sentinel-1, insensible aux nuages, lèverait la principale contrainte d'observation. Des modèles spatio-temporels, tels que les réseaux convolutifs récurrents ou les transformeurs, pourraient affiner la prédiction du risque en exploitant la trajectoire temporelle de chaque secteur. Un système d'alertes en temps quasi réel renforcerait l'utilité opérationnelle de la plateforme pour les gestionnaires forestiers. Une campagne de validation par points GPS de terrain, croisée avec les données de Hansen, consoliderait la fiabilité des cartes produites. Enfin, l'extension de la démarche à d'autres provinces de la forêt équatoriale congolaise en éprouverait la généralité.

BIBLIOGRAPHIE

1. BREIMAN, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
2. CHEN, T. et GUESTRIN, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
3. DRUSCH, M. et al. (2012). Sentinel-2: ESA's Optical High-Resolution Mission for GMES Operational Services. *Remote Sensing of Environment*, 120, 25–36.
4. FAO (2020). Évaluation des ressources forestières mondiales 2020. Rome : Organisation des Nations Unies pour l'alimentation et l'agriculture.
5. GIEC (2006). Lignes directrices pour les inventaires nationaux de gaz à effet de serre, volume 4 : Agriculture, foresterie et autres affectations des terres. Genève.
6. GORELICK, N. et al. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202, 18–27.
7. HANSEN, M. C. et al. (2013). High-Resolution Global Maps of 21st-Century Forest Cover Change. *Science*, 342(6160), 850–853.
8. RONNEBERGER, O., FISCHER, P. et BROX, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 234–241.
9. TUCKER, C. J. (1979). Red and photographic infrared linear combinations for monitoring vegetation. *Remote Sensing of Environment*, 8(2), 127–150.

WEBIOGRAPHIE

1. Global Forest Watch, <https://www.globalforestwatch.org>, consulté le 10 juillet 2026.
2. Programme Copernicus / Sentinel-2, Agence spatiale européenne, <https://sentinels.copernicus.eu>, consulté le 10 juillet 2026.
3. Google Earth Engine, <https://earthengine.google.com>, consulté le 10 juillet 2026.
4. Central African Forest Initiative (CAFI), <https://www.cafi.org>, consulté le 10 juillet 2026.

ANNEXES

Annexe A. Structure du dépôt de code

Le dépôt s'organise en répertoires : config (configuration centralisée), src (modules data, preprocessing, models, visualization, analysis, api et utils), streamlit_app (tableau de bord), frontend (application web React), notebooks (exploration, prétraitement, modélisation, résultats), scripts (automatisation), tests (suite pytest), data (raw, processed, models) et docs (documents académiques).

Annexe B. Lancement du projet en mode démonstration

Quatre commandes suffisent : make seed génère les données de démonstration et entraîne les modèles ; make api démarre l'API FastAPI ; make dashboard démarre le tableau de bord Streamlit ; make frontend démarre le frontal React. La suite de tests s'exécute avec make test et le présent document se régénère avec make monograph.

Annexe C. Principaux points d'entrée de l'API

L'API expose notamment : les routes d'authentification (inscription, connexion, vérification du code à deux facteurs) ; les statistiques de perte forestière par année ; la synthèse des zones à risque par année ; les performances des modèles ; les émissions de CO2 et leurs équivalences ; les alertes de déforestation détectées ; le signalement citoyen ; et les routes d'administration réservées (utilisateurs, journaux d'activité).

Annexe D. Captures d'écran

Insérer ici les captures d'écran du tableau de bord Streamlit, de la documentation interactive de l'API, du frontal web et de l'animation retraçant l'évolution 2015–2025 de la zone d'étude.